심층신경망(Deep Neural Network)

Problem

1. NN을 이용한 XOR 문제 해결
2. DNN을 통한 어려운 문제 도전
3. DNN에서 Backpropagration하면 Gradient Vanishing 문제 발생

Geoffrey Hinton's summary

1. Labeled datasets were too small.
2. Computers were too slow.
3. We initialed the weights in a stupid way.
4. We used the wrong type of non-linearity.

활성 함수(Activation Function)

: 신경학적으로 뉴런 발사 과정

⇒ 입력 신호가 일정 기준을 만족하면 출력 신호를 다음 뉴런으로 보냄을 결정

1. Step

- 입력이 양수일 때 1, 음수일 때는 0

BUT 미분 불가능으로 모델 Optimization에 사용하기 어려워 활성 함수로 사용X

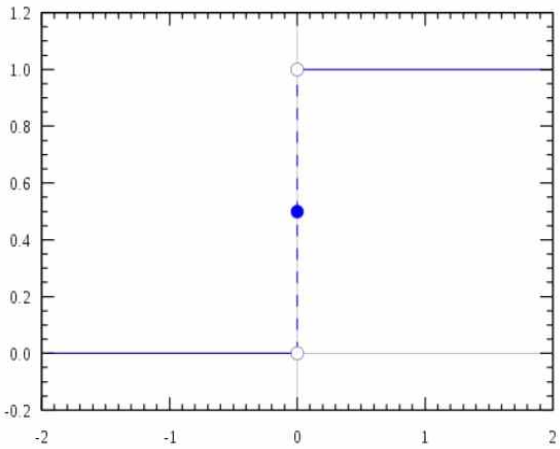

2. Sigmoid

- 단일 퍼셉트론에서 사용한 활성 함수
- 입력을 (0, 1) 사이로 정규화(normalization)

BUT (−∞, −2)와 (2, ∞)에서 미분 값이 0에 가깝게 비슷하다

plus. (−2, 2)에서 미분 값이 작다

⇒ Backpropagation에서 layer를 거칠 때마다 작은 미분 값이 곱해져 Gradient Vanishing을 야기한다(MLP에서 학습이 잘 안 된 원인)

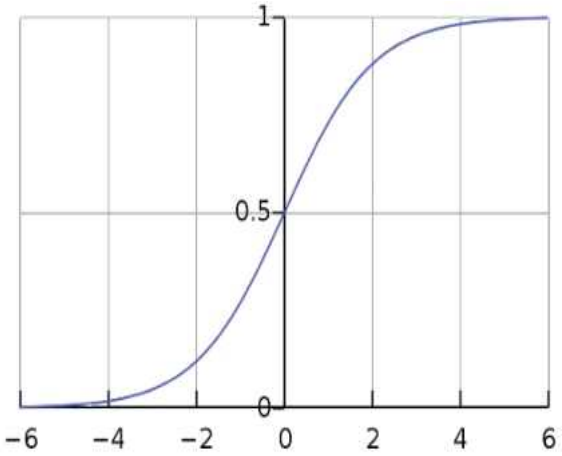

$$sigmoid(x) = \frac{1}{1+e^{-x}}$$

3. tanh

- Sigmoid를 보완하기 위해 제안된 활성 함수

  plus. (−2, 2)에서 미분 값 크다
- 입력을(−1, 1) 사이의 값으로 정규화
- Sigmoid 보다 전반적으로 성능이 좋다

BUT Sigmoid보다는 덜 하지만 여전히 Gradient Vanishing 문제는 발생한다

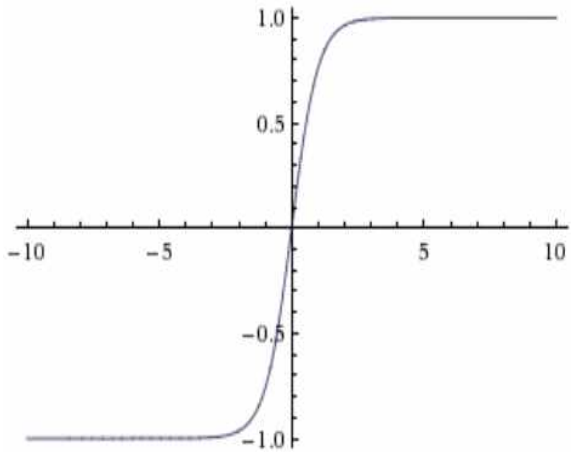

$$\tanh(x) = \frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}$$

4. ReLU(Rectified Linear Unit)

- 가장 인기있는 활성 함수
- 양수에서는 linear function과 같고, 음수에서는 0을 출력
- 미분 값을 0 또는 1의 값을 가지므로 Gradient Vanishing 발생X
- linear function과 같은 문제 발생X

  엄연히 non-linear function이므로 layer를 깊게 쌓을 수 있다
- exp() 함수를 실행하지 않아 sigmoid나 tanh보다 6배 정보 빠르다

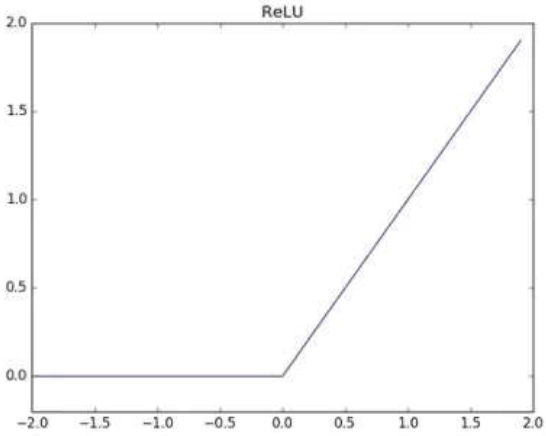

$$Relu(x) = \max(0, x)$$

But "dying ReLU" 현상 발생: $x < 0$에서 $Relu(x) = 0$

5. Leaky ReLU

- "dying ReLU" 현상 해결하기 위해 제시된 활성 함수
- $x < 0$에서 작은 기울기 부여한다(보통 작은 기울기 = 0.01)
- Leaky ReLU로 성능 향상했다는 보고가 있으나 항상 그렇지는 않다

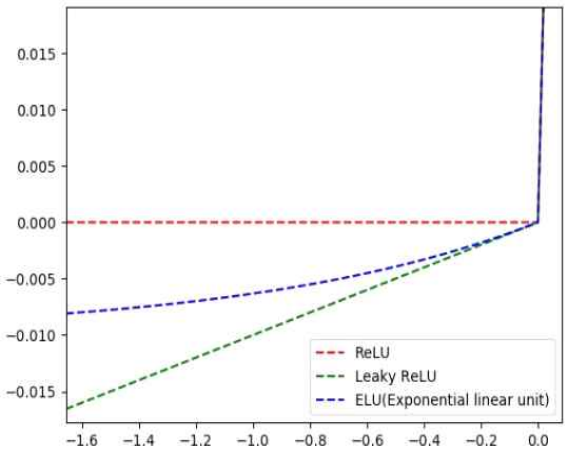

$$Leaky\,Relu(x) = \max(0.01x, x)$$

6. ELU(Exponential Linear Units)

- ReLU의 threshold를 -1로 낮춘 함수를 e^x를 이용하여 근사한 활성 함수
- "dying ReLU" 문제를 해결한다
- 출력 값이 거의 zero-centered에 가깝다

BUT ReLU, Leaky ReLU와 달리 e^x를 계산해야 하는 비용이 든다

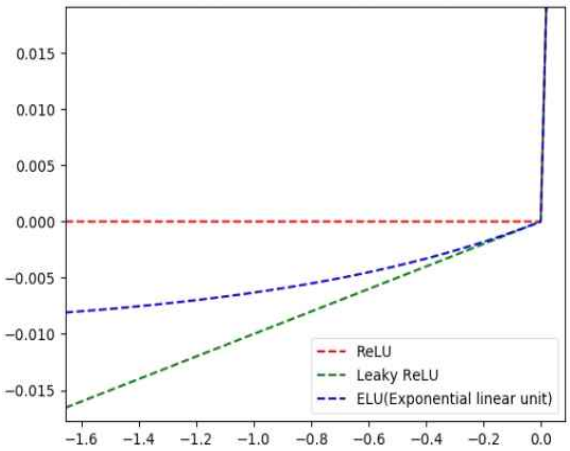

$$f(x) = \begin{cases} x & \text{if } x > 0 \\ \alpha(e^x - 1) & \text{if } x \leq 0 \end{cases}$$

7. Maxout

- ReLU와 Leaky ReLU를 일반화한 활성 함수
  ReLU와 Leaky ReLU는 Maxout의 특수한 경우
- ReLU의 장점을 모두 갖고 있고 "dying ReLU" 문제도 해결

BUT ReLU와 달리 한 뉴런에 대해 파라미터가 2배이므로 전체 파라미터가 증가

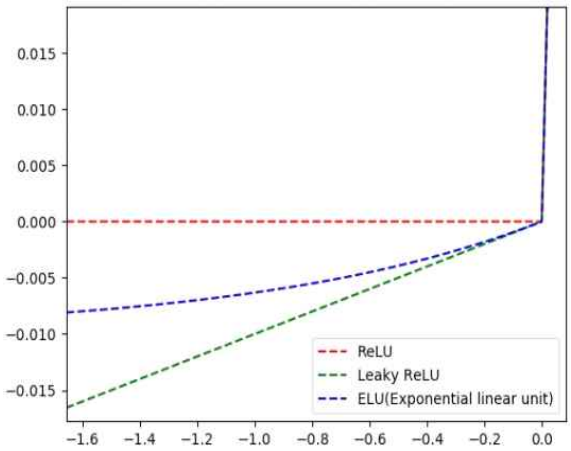

$$f(x) = \max(w_1^T x + b_1, w_2^T x + b_2)$$

1. 가장 먼저 ReLU 시도한다
2. 다음으로 Leaky ReLU, Maxout, ELU 시도한다
   성능이 좋아질 가능성이 있다 but 반드시 좋아지는 것은 아니다
3 tanh 사용해도 되지만 성능이 개선될 확률은 적다
※ 앞으로 DNN에서 Sigmoid는 피한다

성능: $Maxout > ELU, Leaky\,ReLU \geq ReLU > tanh \geq Sigmoid$

Init method	maxout	ReLU	VLReLU	tanh	Sigmoid
LSUV	**93.94**	**92.11**	92.97	89.28	n/c
OrthoNorm	93.78	91.74	92.40	89.48	n/c
OrthoNorm-MSRA scaled	–	91.93	**93.09**	–	n/c
Xavier	91.75	90.63	92.27	**89.82**	n/c
MSRA	n/c†	90.91	92.43	89.54	n/c

"All You Need is a Good INIT", ICLR2016
The Compatibility of activation functions and initialization
Dataset: CIFAR-10

CIFAR-10: 32×32 픽셀의 60,000개 이미지
각 이미지는 10개의 클래스로 라벨링되어 있다
32×32의 1D 벡터를 처리하는 것처럼 사용

가중치 초기화(Weight Initialization)

지금까지 기본적인 선형 회귀나 Softmax와 같은 알고리즘에서는 -1 ~ 1의 난수를 weight로 사용했지만, NN에서는 weight 선정에 주의해야 한다

⇒ w = 0이면 Backpropagation 시 gradient 값이 0이 되어
Gradient Vanishing 현상 발생

※ 절대 0으로 초기화하지 않아야 한다

1. RBM(Restricted Boatman Machine)

Hinton et al.(2006) "A Fast Learning Algorithm for Deep Belief Nets"
- too complicated

2. Xavier initialization

– 노드의 입력(fan_in)의 수와 출력(fan_out)의 수에 비례해서 초기값을 결정

W = np.random.randn(fan_in, fan_out)/np.sqrt(fan_in)

$$std = gains \times \sqrt{\frac{2}{fan-in+fan-out}}$$

X. Glorot and Y. Bengio “Understanding the difficulty of training deep feedfor ward neural networks,” in International conference on artificial intelligence an d statistics, 2010

3. He's initialization = MSRA

– 노드의 입력(fan_in)의 수와 출력(fan_out)의 수에 비례해서 초기값을 결정

W = np.random.randn(fan_in, fan_out)np.sqrt(fan_in/2)

$$std = \frac{gain}{\sqrt{fan-mode}}$$

K. He, X. Zhang, S. Ren, and J. Sun “Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification,” 2015

[PyTorch 초기화 torch.nn.init]

드랍아웃(Dropout)

목적: Overfitting을 줄이기

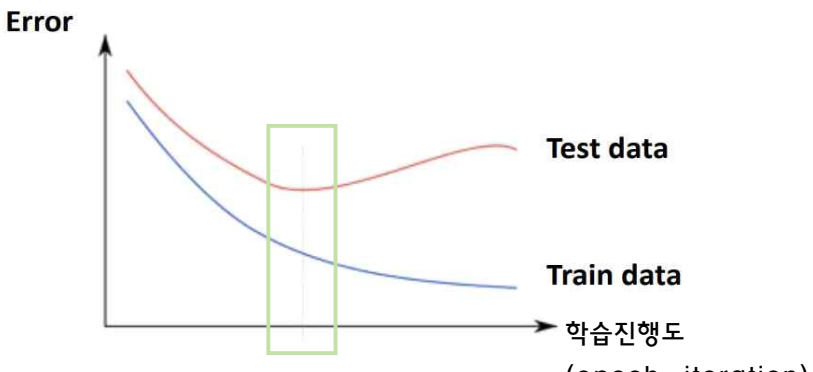

Overfitting의 순간
test data와 train data의 error 차 증가

Solution

1. More Training data
2. Reduce the number of feature
3. Regularization ex. Dropout

드랍아웃(Dopout)

: 신경망에서 유닛 제거(매 학습에 비율 0.3 ~ 0.5 정도가 좋다)

훈련 데이터에 대한 복잡한 공동 적응 방지하여 Overfitting 줄이기

※ 학습에서만 적용하고 테스트에서는 모든 유닛을 사용함

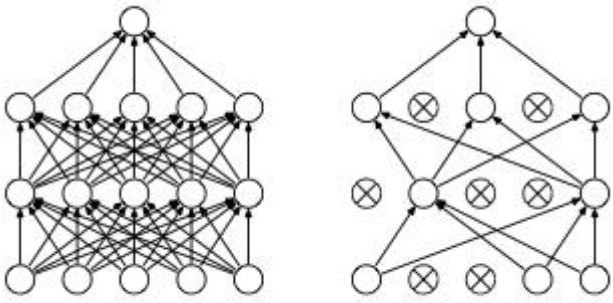

(a) Standard Neural Net (b) After applying dropout.

매번 무작위 유닛이 Dropout되어 Ensemble과 같은 효과를 보여준다

torch.nn.Dropout(p=0.5, inplace=False)

Tips for DNN

1. 활성 함수(Activation Function)을 잘 선택한다

ReLU가 가장 널리 사용된다

2. 가중치 초기화(Weight Initialization)을 잘 선택한다

Xavier가 가장 널리 사용된다

3. 드랍 아웃(Dropout)을 잘 적용한다

NN-ReLU-Dropout를 하나의 블락으로 쌓는다