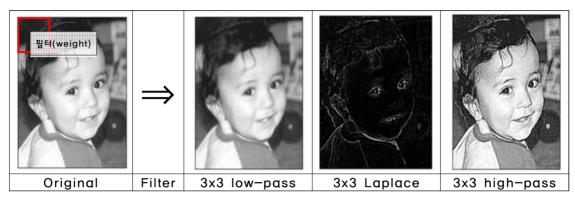
## 합성곱신경망(CNN. Convolutional Neural Network)

변환 불변성에 기초하여 이미지를 분석에 사용하는 깊은 인공신경망의 한 종류 필터 역할을 스스로 학습하여 상대적으로 전처리를 거의 사용하지 않는다

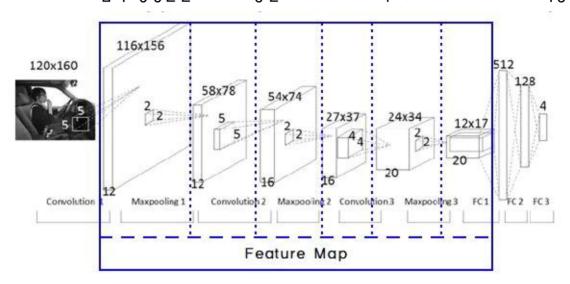
Convolution: filter 연산에서 사용되어 영상에서 feature를 추출할 때 사용



Convolution의 과정	1 1 1 0 0 0 1 1 1 0 0 0 1 1 1 0 0 1 1 0 0 1 1 0 0 * 1 0 1 (Fi	ilter, Kernel, Weight)			
	Image Convolved Feature				
	1 x1 1 x0 1 x1 0 0       0 x0 1 x1 1 x0 1 0       0 x1 0 x0 1 x1 1 1       0 0 1 1 0       0 1 1 0	<b>⇒</b> 4   1   1   1   1   1   1   1   1   1			
	1  1 x1 1 x0 0 x1 0 0 0 0 1 x0 1 x1 1 x0 0 0 0	4 3			
	<b>.</b>				
	Green: 영상 이미지 Yellow: Convolution이 일어나는 영역 Red: Convolution Kernel				

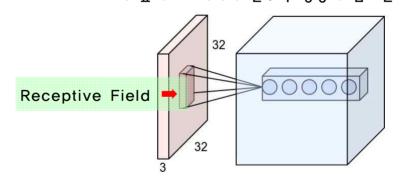
Convolution + NN : Convolution을 사용하는 신경망 연산 2개 이상의 CNN layer

& 입력 영상뿐만 아니라 중간 Feature map에도 Convolution 적용



## Receptive Field(수용 영역)

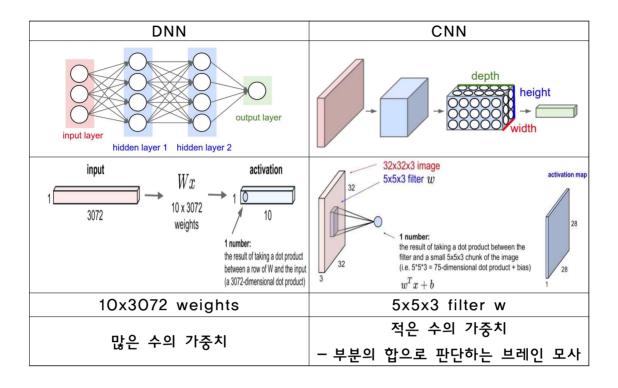
: 출력 layer의 뉴런 하나에 영향을 미치는 입력 뉴런들의 공간 크기 외부 자극이 일부 영역에만 영향을 미친다(전체에 영향 X) 영상에서 특정 위치에 있는 픽셀들은 주변에 있는 일부 픽셀들과만 correlation이 높다 → 거리가 멀수록 영향이 감소한다

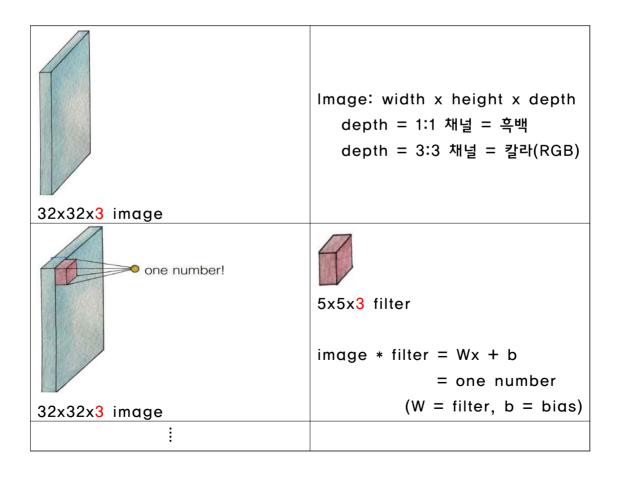


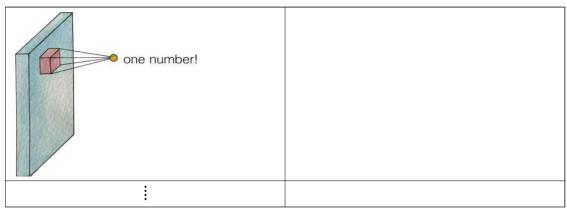
### CNN의 장점

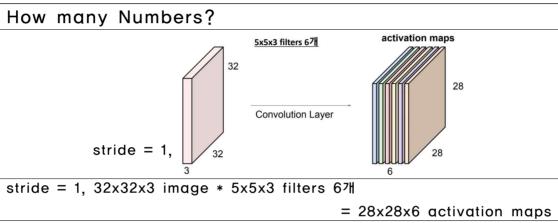
영상을 2D에서 1D로 평탄화하지 않으므로, 형상을 유지한다

∴ 입출력 모두 3차원 데이터로 처리하기 때문에 공간적 정보를 유지할 수 있다





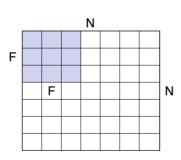




Stride: Filter가 움직이는 정보

stride = n : n칸씩 움직인다

### Output size 구하기



$$(N - F) / stride + 1$$

ex) 
$$N = 7$$
,  $F = 3$ 

stride = 1 : (7-3)/1+1 = 5 (ok)

stride = 2 : (7-3)/2+1 = 3 (ok)

stride = 3 : (7-3)/3+1 = 2.33 (X)

stride = 4 : (7-3)/4+1 = 2 (ok)

### Padding: 영상 사이즈 유지하기

ex) input 7x7 image pad with 1 pixel border(회색)

if. pad의 값 = 0 : zero pad

 $\leftarrow$  zero pad with 1

ex)

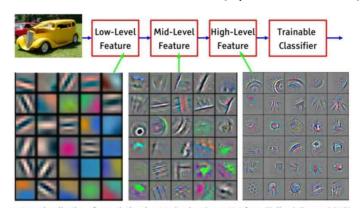
Kernel에 따른 Padding의 크기 = (F / 2)의 소수점 첫째 자리 올림

F = 3 : zero pad with 1 F = 5 : zero pad with 2 F = 7 : zero pad with 3

## Convolution 결과의 Size 구하기

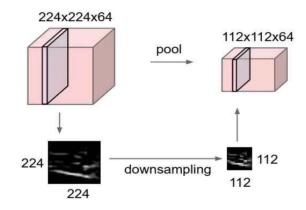
	Parameter	
Input: $W_1  imes H_1  imes D_1$	Filter의 개수: $K_1$	
	Filter의 한 변 크기: $F_1$	
	Stride: $F$	
	Zero Pad의 개수: $S$	
	$W_2 = (W_1 - F + 2P)/S + 1$	
Output: $W_2 \times H_2 \times D_2$	$H_2 = (H_1 - F + 2P)/S + 1$	
	$D_2 = K$	
	→ filter 개수로 output의 depth 정할 수 있다	
with parameter sharing, $F ullet F ullet D_1$ weight per filter		
$total  \Rightarrow  (F  \bullet  F  \bullet  D_1)  \bullet  K   weights   and   K   biases$		

## 1. Visualization of Activation Map(Feature Map)



### 2. Pooling Layer(Sampling)

: resizing Conv layer



### Max Pooling

Filter 내에서 가장 큰 값 선택 ⇒ 더 강한 특징만 남는다

	()	Sing	gle d	epth	slice				빨강색 네모에서 가장 큰 값: 6
x		1	1	2	4	max pool with 2x2 filters			
		5	6	7	8	and stride 2	6	8	초록색 네모에서 가장 큰 값: 8
		3	2	1	0		3	4	
		1	2	3	4				노랑색 네모에서 가장 큰 값: 3
			ë 3		y				파랑색 네모에서 가장 큰 값: 4

#### Average Pooling Filter 내에서 평균값 선택

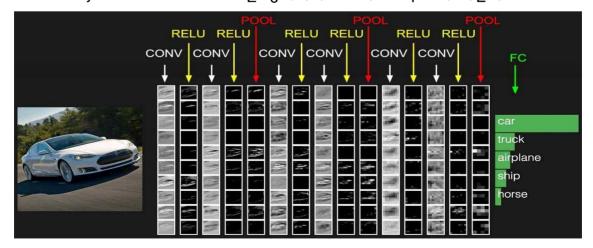
У

⇒ Spatial Structure만 보존하여 이미지가 smooth 해진다 빨강색 네모에서 평균값: Single depth slice (1+1+5+6)/42 4 Χ 초록색 네모에서 평균값: Average Pool with 2x2 filters 13/4 21/4 7 and stride 2 (2+4+7+8)/48/4 8/4 1 노랑색 네모에서 평균값: (3+2+1+2)/41 3 4

파랑색 네모에서 평균값:

(1+0+3+4)/4

- (2x2 filter의 경우) 전체 데이터의 75%를 버리고 25%만 선택
  - → Computatioinal Complexity 감소한다
- Depth를 줄이지 않고 Spatially하게만 줄인다(Height & Width) 32x32x3 → 16x16x3
- Q) Stride와 Pooling 모두 down-sampling인데 어느 것 사용?
  A) 최근 CNN 아키텍쳐는 stride를 사용하는 경우가 많다(stride 추천)
- 3. FC layer(Fully Connected Layer)
  마지막 Pooling layer를 통과한 데이터가 1x1024 feature를 갖는다면
  FC layer with W=1024x5를 통과하여 1x5의 Output이 나온다



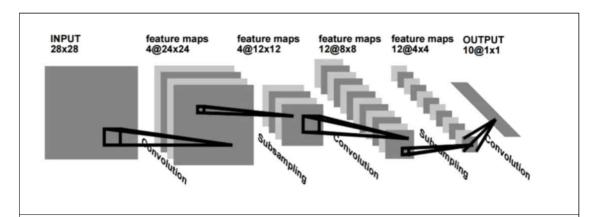
# CNN 영상 분류기

## MNIST: Image Classification

	Descline Linear		One-Hidden-Layer		Two-Hidden-Layer	
DNN Baseline Linea	ur	Fully Connected		Fully Connected		
	Classifer		Multi-layer NN		Multi-layer NN	
Error	8.4%		3.6% to 3.8%		2.95% to 3.05%	
CNINI	LoNet 1		a Nat 4	LaNat	E	Boosted
CNN LeNet-1 L		.eNet-4 LeNet-9		5	LeNet-4	
Error	1.7%	1,1%		0.95%		0.7%

Baseline Linear	One-Hidden-Layer	Two-Hidden-Layer	
Classifer	Fully Connected	Fully Connected	
Classiler	Multi-layer NN	Multi-layer NN	
	20x20 → 1000 → 10:	28x28 →300→100→10:	
20,420 . 10: 0,550 8 4%	error 3.8%	error 3.05%	
20x20 → 10: error 8.4%	20x20 → 300 → 10:	28x28 →1000→150→10:	
	error 3.6%	error 2.95%	
20×20 : :	400 300/1000 20×20 : : :	784 300/ 100/ 784 1000 150 10 28×28 i i i i i	

#### LeNet-1



C1: Conv(in = 1, out = 4, kernel = 5, stride = 1, padding = 0) +X1: tanh()

S2: AvgPooling(in = 4, out = 4, kernel = 2, stride = 2) +X2: tanh()

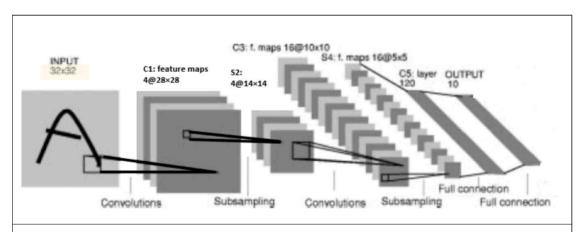
C3: Conv(in = 4, out = 12, kernel = 5, stride = 1, padding = 0) +X3: tanh()

S4: AvgPooling(in = 12, out = 12, kernel = 2, stride = 2) +X4: tanh()

Output: Conv(in = 12, out = 10, kernel = 3) + Sigmoid()

• Conv(in = 12, out = 10, kernel = 3) + Sigmoid() == FC Layer

#### LeNet-4



C1: Conv(in = 1, out = 4, kernel = 5, stride = 1, padding = 0) +X1: tanh()

S2: AvgPooling(in = 4, out = 4, kernel = 2, stride = 2) +X2: tanh()

C3: Conv(in = 4, out = 16, kernel = 5, stride = 1, padding = 0) +X3: tanh()

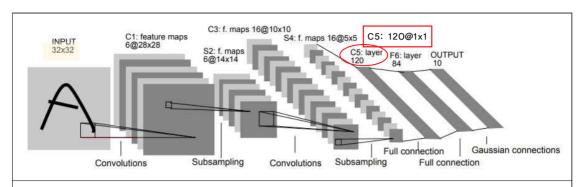
S4: AvgPooling(in = 16, out = 16, kernel = 2, stride = 2) +X4: tanh()

C5: Conv(in = 16, out = 120, kernel = 5, stride = 1, padding = 0)

Output: Conv(in = 120, out = 10) + sigmoid()

※ FC Layer 2개: C5, Output

#### LeNet-5



C1: Conv(in = 1, out = 6, kernel = 5, stride = 1, padding = 0) +X1: tanh()

S2: AvgPooling(in = 6, out = 6, kernel = 2, stride = 2) +X2: tanh()

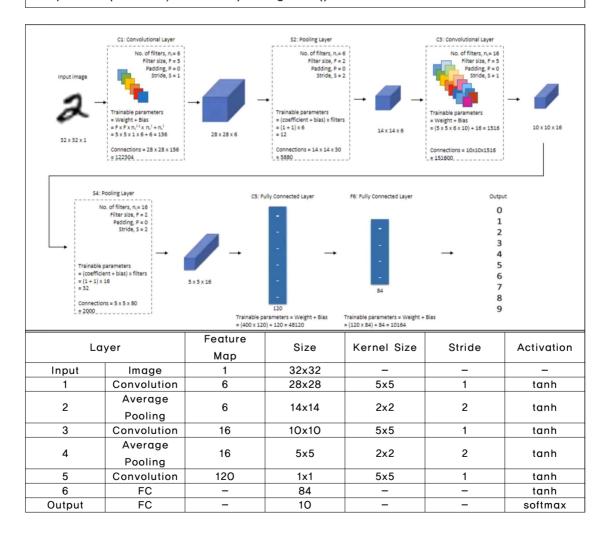
C3: Conv(in = 6, out = 16, kernel = 5, stride = 1, padding = 0) +X3: tanh()

S4: AvgPooling(in = 16, out = 16, kernel = 2, stride = 2) +X4: tanh()

C5: Conv(in = 16, out = 120) +X5: tanh()

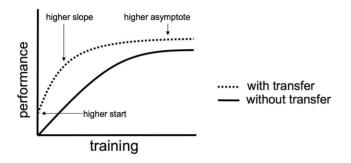
F6: FC(in = 120, out = 84) + X6: tanh()

Output: FC(in = 84, out = 10) + sigmoid()



## 전이 학습(Transfer Learning)

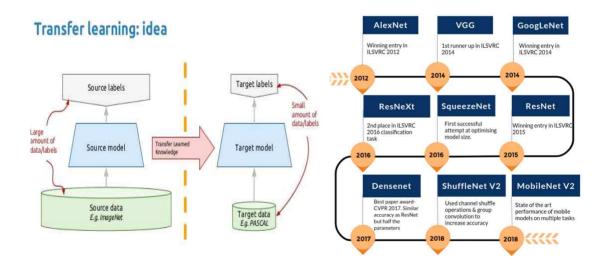
: 이미 학습된 신경망 능력을 유사하거나 전혀 새로운 분야의 신경망 학습에 사용 높은 정확도를 비교적 짧은 시간 내에 달성 가능



컴퓨터 비전에서의 전이 학습 = 사전 학습된 모델(pre-trained model) 이용

## 사전 학습된 모델(Pretrained Model)

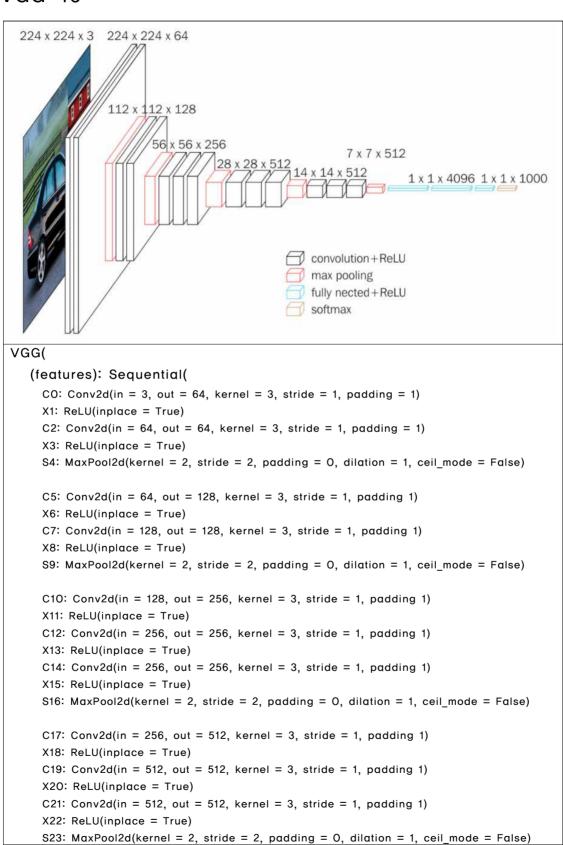
: 풀고자 하는 문제와 비슷하고 사이즈가 큰 데이터로 이미 학습이 된 모델 오랜 시간과 연산량으로 학습되어 있다 어려운 문제를 잘 풀면, 쉬운 문제도 잘 풀 것으로 기대한다



※ Pretrained Model의 입력 사이즈에 맞게

입력 영상 사이즈를 Resize 해야 한다

#### VGG-16



```
C24: Conv2d(in = 512, out = 512, kernel = 3, stride = 1, padding 1)
    X25: ReLU(inplace = True)
     C26: Conv2d(in = 512, out = 512, kernel = 3, stride = 1, padding 1)
    X27: ReLU(inplace = True)
     C28: Conv2d(in = 512, out = 512, kernel = 3, stride = 1, padding 1)
    X29: ReLU(inplace = True)
     S30: MaxPool2d(kernel = 2, stride = 2, padding = 0, dilation = 1, ceil_mode = False)
   )
   (avgpool): AdaptiveAvgPool2d(output size = (7, 7)
   (classifier): Sequential(
      (0): Linear(in = 25088, out = 4096, bias = True)
      (1): ReLU(inplace = True)
      (2): Dropout(p = 0.5, inplace = False)
      (3): Linear(in = 4096, out = 4096, bias = True)
      (4): ReLU(inplace = True)
      (5): Dropout(p = 0.5, inplace = False)
      (6): Linear(in = 4096, out = 10000, bias = True)
  )
import torchvision, models as models
vgg16 = models.vgg16(pretrained = True).to(device)
```

### 영상 분류 데이터셋

#### 1. MNIST Dataset

클래스: 10개

학습데이터: 60,000장 테스트데이터: 10,000장

해상도: 28x28

### 2. Fashion-MNIST Dataset

	10개의 카테고리 범주		
	70,000개의 흑백 이미지		
	28x28 이미지 해상도		
	레이블	클래스	
	0	T-shirt/top	
	1	Trouser	
	2	Pullover	
and the same of th	3	Dress	
THEY AND A LONG TO THE TOTAL OF THE	4	Coat	
	5	Sandal	
## # # # # # # # # # # # # # # # # # #	6	Shirt	
	7	Sneaker	
	8	Bag	
ng sababan nang ng sa	9	Ankie boat	

### 3. CIFAR-10



클래스: 10개

클래스당: 6,000장

학습 데이터: 50,000장 테스트 데이터: 10,000장

해상도: 32x32

#### 4. CIFAR-100

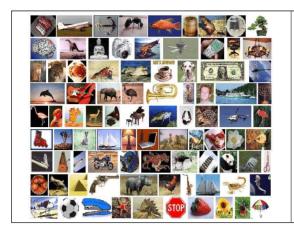


클래스: 100개 클래스당: 600장

학습 데이터: 50,000장 테스트 데이터: 10,000장

해상도: 32x32

### 5. Caltech101, 2003년



클래스: 101개 + 배경 전체 이미지: 9144장 해상도: 300x200

### 6. Caltech256, 2006년



클래스: 256개 + 배경 전체 이미지: 30,608장 클래스별: 80~827장 해상도: 300x200

### 7. ImageNet, 2009년



클래스: 1000개

전체 이미지: 14백만장

학습 데이터: 138G 테스트 데이터: 6.3G

### Benchmark

### 1. CIFAR-10

Model	Accuracy			
VGG16	92.64%			
ResNet18	93.02%			
ResNet50	93.62%			
ResNet101	93.75%			
RegNetX 200MF	94.24%			
RegNetY 400MF	94.29%			
MobileNetV2	94.43%			
ResNeXt29(32x4d)	94.73%			
ResNeXt29(2x64d)	94.82%			
DenseNet121	95.04%			
PreActResNet18	95.11%			
DPN92	95.16%			

## 2. ImageNet

